

آمار و احتمال مهندسی

اساتید: دکتر توسلی پور، دکتر وهابی

دانشکده مهندسی برق و کامپیوتر، دانشکدگان فنی، دانشگاه تهران



پاسخ تمرین چهارم - توزیع های شرطی، توزیع بتا، کوواریانس و همبستگی

طراح: مصطفی کرمانی نیا

سوپروایزر: سالار صفردوست

تاریخ تحویل: ۱۸ آذر ۱۴۰۳

بیشتر بدانیم: پارادوکس سیمپسون

تصور کنید یک بیمارستان در حال مقایسه دو درمان A و B برای یک بیماری خاص است. آن‌ها داده‌هایی درباره‌ی نرخ موفقیت این دو درمان در دو گروه سنی مختلف بیماران جوان‌تر (زیر ۵۰ سال) و بیماران مسن‌تر (۵۰ سال و بالاتر) جمع‌آوری کرده‌اند:

گروه سنی	درصد موفقیت درمان A	درصد موفقیت درمان B
بیماران جوان‌تر	۳۰٪ (۱۵۰ از ۵۰)	۵۰٪ (۳۶۰ از ۱۸۰)
بیماران پیرتر	۸۰٪ (۲۵۰ از ۲۰۰)	۹۰٪ (۴۰ از ۳۶)

در جدول بالا مشاهده می‌شود که درمان B هم برای بیماران جوان‌تر و هم برای بیماران پیرتر درصد موفقیت بالاتری از درمان A دارد. حال سعی می‌کنیم از این جدول، جدول دیگری برای بررسی عملکرد درمان‌ها روی کل بیماران بنویسیم:

درمان	تعداد موفقیت‌ها	تعداد بیماران	درصد موفقیت کلی
درمان A	۲۵۰	۴۰۰	۶۲,۵٪
درمان B	۲۱۶	۴۰۰	۵۴٪

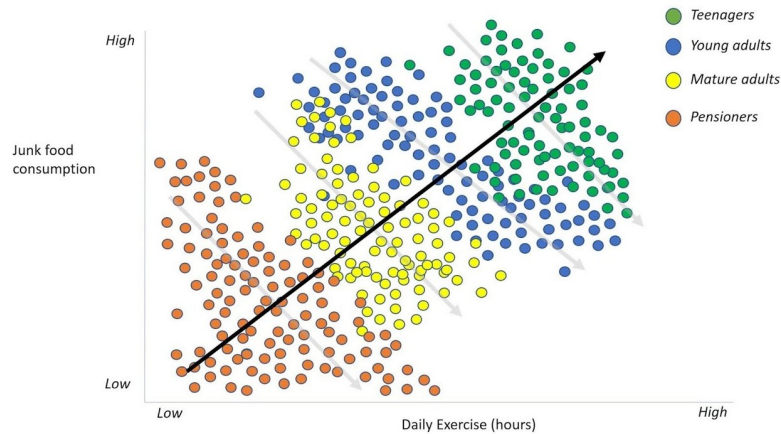
با بررسی درصد کلی موفقیت درمان‌ها دیده می‌شود که برعکس روند عملکرد درمان‌ها روی زیرگروه‌ها، درمان A در حالت کلی موفق‌تر از درمان B بوده است!

این وضعیت به ظاهر متناقض، نمونه‌ای از پارادوکس سیمپسون است که اولین بار توسط آمارشناس بریتانیایی ادوارد سیمپسون در سال ۱۹۵۱ توصیف شد. به طور کلی این پدیده زمانی رخ می‌دهد که یک روند مشاهده‌شده در چندین گروه مختلف، زمانی که داده‌ها با هم ترکیب می‌شوند، معکوس می‌شود. این پدیده نشان می‌دهد که برای انجام یک تحلیل صحیح و دقیق، باید به جزئیات داده‌ها توجه کرده و تأثیر متغیرهای مختلف را در نظر گرفت. نادیده گرفتن این متغیرهای پنهان و تأثیرگذار می‌تواند به نتایجی منجر شود که نه تنها نادرست هستند، بلکه می‌توانند به تصمیم‌گیری‌های اشتباه و پیامدهای جدی منجر شوند. این موضوع به ویژه در حوزه‌هایی مثل پزشکی، علوم اجتماعی و سیاست‌گذاری عمومی بسیار حیاتی است، چرا که اشتباهات آماری می‌توانند عواقب گسترده‌ای داشته باشند.

مثالی دیگر که می‌تواند باعث پیدا کردن شهود بیشتری نسبت به این پدیده شود در زیر توضیح داده شده است:

فرض کنید شکل نمایش داده شده حاصل نمونه‌برداری از جامعه‌ای خاص بوده باشد. دیده می‌شود که در بازه‌های سنی مختلف، میان مدت زمان ورزش انجام شده و میزان مصرف غذاهای ناسالم ارتباط (همبستگی) معکوسی وجود دارد. اما در صورتی که تمامی نمونه‌ها را با هم در نظر بگیریم، دیده می‌شود که برخلاف انتظار رابطه‌ی بین مدت زمان ورزش و مصرف غذای ناسالم به صورت مستقیم است. به همین دلیل اگر شخصی به خوبی از جزئیات مسئله آگاه نداشته باشد، محتمل است که نتیجه‌گیری اشتباهی از روی داده‌ها انجام دهد.

نکته: برای مثال اول نیز می‌توان مشابه این نمودار را با در نظر گرفتن پارامترهای نوع درمان و نتیجه‌ی درمان به عنوان متغیرهای محورهای نمودار رسم کرد، اما چون هر کدام از این متغیرها تنها دو حالت دارند، نمی‌توان از روی نمودار این پدیده را مشاهده کرد.



۱. سکه‌بازی

۲۰ نمره

یک سکه را سه بار پرتاب می‌کنیم. X را مساوی تعداد شیرها در دو پرتاب اول و Y را مساوی تعداد شیرها در دو پرتاب آخر می‌گذاریم.

(الف) جدول احتمال را برای X و Y بکشید. (۷ نمره)

(ب) به کمک جدول بخش الف، $P(X < 2 | Y = 1)$ و $P(Y = 2 | X = 1)$ را بنویسید. (۵ نمره)

(ج) $Cov(X, Y)$ را محاسبه کنید. (۸ نمره)

پاسخ:

(الف) تمام ۸ حالت مختلف را برای ۳ پرتاب در نظر گرفته و طبق آن‌ها، جدول را تکمیل می‌کنیم:

$X \backslash Y$	0	1	2	$p(x_i)$
0	1/8	1/8	0	1/4
1	1/8	2/8	1/8	1/2
2	0	1/8	1/8	1/4
$p(y_j)$	1/4	1/2	1/4	1

(ب)

$$P(X < 2 | Y = 1) = \frac{P(X < 2 \wedge Y = 1)}{P(Y = 1)} = \frac{\frac{1}{8} + \frac{2}{8}}{\frac{1}{2}} = \frac{\frac{3}{8}}{\frac{1}{2}} = \frac{3}{4}$$

$$P(Y = 2 | X = 2) = \frac{P(Y = 2 \wedge X = 2)}{P(X = 2)} = \frac{\frac{1}{8}}{\frac{1}{4}} = \frac{1}{2}$$

(ج)

روش اول:

با توجه به تعریف کواریانس داریم:

$$\text{Cov}(X, Y) = E((X - E(X))(Y - E(Y)))$$

با توجه به جدول، داریم:

$$E(X) = \sum_{i=0}^2 x_i \cdot p(x_i) = 0 \cdot \frac{1}{4} + 1 \cdot \frac{1}{2} + 2 \cdot \frac{1}{4} = 1$$

$$E(Y) = \sum_{i=0}^2 y_i \cdot p(y_i) = 0 \cdot \frac{1}{4} + 1 \cdot \frac{1}{2} + 2 \cdot \frac{1}{4} = 1$$

رابطه ی کواریانس را باز می کنیم:

$$\begin{aligned} \text{Cov}(X, Y) &= E((X - 1)(Y - 1)) = \sum_{i,j} (x_i - 1)(y_j - 1) \cdot p(x_i, y_j) \\ &= (0 - 1)(0 - 1) \cdot \frac{1}{8} + (0 - 1)(1 - 1) \cdot \frac{1}{8} + (0 - 1)(2 - 1) \cdot 0 + \\ &\quad (1 - 1)(0 - 1) \cdot \frac{1}{8} + (1 - 1)(1 - 1) \cdot \frac{2}{8} + (1 - 1)(2 - 1) \cdot \frac{1}{8} + \\ &\quad (2 - 1)(0 - 1) \cdot 0 + (2 - 1)(1 - 1) \cdot \frac{1}{8} + (2 - 1)(2 - 1) \cdot \frac{1}{8} \\ &= \frac{1}{8} + \frac{1}{8} = \frac{1}{4} \end{aligned}$$

روش دوم:

با توجه به تعریف کواریانس داریم:

$$\text{Cov}(X, Y) = E(XY) - E(X)E(Y)$$

حالا با توجه به جدول، داریم:

$$E(XY) = \sum_{i,j} x_i y_j \cdot p(x_i, y_j) = 1 \cdot 1 \cdot \frac{2}{8} + 1 \cdot 2 \cdot \frac{1}{8} + 2 \cdot 1 \cdot \frac{1}{8} + 2 \cdot 2 \cdot \frac{1}{8} = \frac{10}{8} = \frac{5}{4}$$

$$\text{Cov}(X, Y) = \frac{5}{4} - 1 \cdot 1 = \frac{1}{4}$$

روش سوم:

اگر X_i را نتیجه ی پرتاب i -ام بگذاریم، داریم:

$$\text{Cov}(X, Y) = \text{Cov}(X_1 + X_2, X_2 + X_3)$$

با توجه به خواص کواریانس و استقلال نتایج پرتاب های مختلف سکه، داریم:

$$\text{Cov}(X, Y) = \text{Cov}(X_1, X_2) + \text{Cov}(X_1, X_3) + \text{Cov}(X_2, X_2) + \text{Cov}(X_2, X_3) = \text{Cov}(X_2, X_2) = \text{Var}(X_2)$$

با توجه به اینکه تمامی X_i ها از توزیع Bernoulli(0.5) پیروی می کنند، داریم:

$$\text{Cov}(X, Y) = \text{Var}(X_2) = \frac{1}{4}$$

۲. مصطفی باگزن!

۱۵ نمره

مصطفی در یک شرکت مشغول به کار شده و هر روز هزار خط کد می زند. اما چون در حین کار، با ربات همستر سکه جمع می کند، حواسش پرت می شود و همیشه کدهای باگ دار می زند. تعداد باگ های مصطفی در یک روز، متغیر تصادفی N با توزیع پواسون با پارامتر λ است.

خوشبختانه امیر هر روز کدهای مصطفی را خوانده و اصلاح می کند. فرض کنید امیر هر باگی را با احتمال p تشخیص داده و اصلاح کند. X را تعداد باگ های اصلاح شده توسط امیر در نظر بگیرید و Y را تعداد باگ هایی که امیر نتوانسته آنها را پیدا کند. (پس $X + Y = N$ است.)

الف) با کمک توزیع جرم احتمال مشترک، نشان دهید که X و Y از هم مستقل اند و $Y \sim \text{Poi}(\lambda(1-p))$ و $X \sim \text{Poi}(\lambda p)$ (۱۰ نمره)

ب) ضریب همبستگی بین X و N را بیابید. (۵ نمره امتیازی)

پاسخ:

الف) می دانیم هر باگی که در کدها بوجود می آید، به احتمال p اصلاح می شود و به احتمال $1-p$ در بین کدها باقی می ماند. پس اگر تعداد کل باگ ها n باشد، تعداد باگ هایی که اصلاح می شوند از توزیع دوجمله ای با پارامترهای p و n پیروی می کنند:

$$X|N=n \sim \text{Bin}(n, p)$$

برای یافتن توزیع X و Y با استفاده از قانون احتمال کل و اینکه $X + Y = N$ داریم:

$$P(X=i, Y=j) = P(X=i, N=i+j) = P(X=i|N=i+j) \cdot P(N=i+j)$$

حالا با توجه به دوجمله ای بودن توزیع $X|N$ و پواسون بودن توزیع N داریم:

$$\begin{aligned} P(X=i, Y=j) &= P(X=i|N=i+j) \cdot P(N=i+j) \\ &= \frac{(i+j)!}{i!j!} p^i (1-p)^j e^{-\lambda} \frac{\lambda^{i+j}}{(i+j)!} = \left(e^{-\lambda p} \frac{(\lambda p)^i}{i!} \right) \times \left(e^{-\lambda(1-p)} \frac{(\lambda(1-p))^j}{j!} \right) = P(X=i) \times P(Y=j) \\ & \quad (X \sim \text{Poi}(\lambda p) \text{ and } Y \sim \text{Poi}(\lambda(1-p))) \end{aligned}$$

* توجه کنید فقط زمانی می توانیم از عبارت $X + Y = N$ وابسته بودن دو متغیر X و Y را نتیجه بگیریم که مقدار N مشخص باشد. اما در این سوال مقدار N مشخص نیست و خودش یک متغیر تصادفی است.

ب) با توجه به تعریف ضریب همبستگی داریم:

$$\rho(X, N) = \frac{\text{Cov}(X, N)}{\sqrt{\text{Var}(X)\text{Var}(N)}}$$

چون متغیرهای X و N توزیع پواسون دارند پس واریانس آن‌ها به ترتیب λp و λ می‌شود. برای محاسبه کوواریانس نیز داریم:

$$Cov(X, N) = Cov(X, X + Y) = E[X(X + Y)] - E[X]E[X + Y] = E[XX + XY] - E[X]E[X + Y]$$

با توجه به خاصیت خطی بودن امید ریاضی می‌توانیم بنویسیم:

$$E[XX + XY] - E[X]E[X + Y] = E[XX] + E[XY] - E[X](E[X] + E[Y]) =$$

$$(E[XX] - E[X]E[X]) + (E[XY] - E[Y]E[X]) = Cov(X, X) + Cov(X, Y)$$

با توجه به استقلال X و Y ، کوواریانس آن‌ها صفر است و همچنین می‌دانیم $Cov(X, X) = Var(X)$. در نهایت با جایگذاری موارد بدست آمده ضریب همبستگی را حساب می‌کنیم:

$$\rho(X, N) = \frac{\lambda p}{\sqrt{\lambda p \times \lambda}} = \sqrt{p}$$

۱۵ نمره

۳. از توام به شرطی

تابع چگالی توام متغیرهای تصادفی X و Y بصورت زیر است:

$$f_{XY}(x, y) = \begin{cases} 1 \cdot xy^2, & 0 \leq x \leq y \leq 1 \\ 0, & \text{در غیر این صورت} \end{cases}$$

الف) توابع چگالی شرطی $f_{X|Y}(x|y)$ و $f_{Y|X}(y|x)$ را بدست آورید. (۸ نمره)

ب) $Cov(X, Y)$ را حساب کنید. (۷ نمره)

پاسخ:

الف) تابع چگالی حاشیه‌ای $f_X(x)$ را محاسبه می‌کنیم:

$$\begin{aligned} f_X(x) &= \int_x^1 1 \cdot xy^2 dy \\ &= 1 \cdot x \left[\frac{y^3}{3} \right]_x^1 = 1 \cdot x \left(\frac{1}{3} - \frac{x^3}{3} \right) = \frac{1}{3} x (1 - x^3) \end{aligned}$$

سپس تابع چگالی شرطی $f_Y(y|x)$ را محاسبه می‌کنیم:

$$f_Y(y|x) = \frac{f_{XY}(x, y)}{f_X(x)} = \frac{1 \cdot xy^2}{\frac{1}{3} x (1 - x^3)} = \frac{3y^2}{1 - x^3} \quad : \quad 0 \leq x \leq y \leq 1$$

برای محاسبه‌ی $f_X(x|y)$ ابتدا $f_Y(y)$ را با انتگرال‌گیری از تابع چگالی مشترک نسبت به x محاسبه می‌کنیم:

$$f_Y(y) = \int_0^y 1 \cdot xy^2 dx$$

$$= 10y^2 \int_0^y x dx = 10y^2 \left[\frac{x^2}{2} \right]_0^y = 10y^2 \times \frac{y^2}{2} = 5y^4$$

سپس تابع چگالی شرطی $f_X(x|y)$ را محاسبه می کنیم:

$$f_X(x|y) = \frac{f_{XY}(x,y)}{f_Y(y)} = \frac{10xy^2}{5y^4} = 2 \frac{x}{y^2} \quad : \quad 0 \leq x \leq y \leq 1$$

به این ترتیب تابع چگالی شرطی $f_X(x|y)$ نیز به دست می آید.

ب) ابتدا $E[XY]$ را محاسبه می کنیم:

$$E[XY] = \int_0^1 \int_x^1 10xy^2 \cdot xy dy dx = \int_0^1 \int_x^1 10x^2y^3 dy dx$$

در اینجا ابتدا انتگرال داخلی را نسبت به y حل می کنیم:

$$\int_x^1 10x^2y^3 dy = 10x^2 \left[\frac{y^4}{4} \right]_x^1 = 10x^2 \left(\frac{1}{4} - \frac{x^4}{4} \right) = \frac{5}{2}x^2(1 - x^4)$$

سپس انتگرال خارجی را نسبت به x محاسبه می کنیم:

$$\begin{aligned} E[XY] &= \int_0^1 \frac{5}{2}x^2(1 - x^4) dx = \frac{5}{2} \int_0^1 (x^2 - x^6) dx \\ &= \frac{5}{2} \left[\frac{x^3}{3} - \frac{x^7}{7} \right]_0^1 = \frac{5}{2} \left(\frac{1}{3} - \frac{1}{7} \right) = \frac{5}{2} \times \frac{4}{21} = \frac{10}{21} \end{aligned}$$

حالا $E[X]$ را محاسبه می کنیم:

$$E[X] = \int_0^1 f_X x dx = \frac{10}{3} \int_0^1 (x^3 - x^5) dx = \frac{10}{3} \left[\frac{x^4}{4} - \frac{x^6}{6} \right]_0^1 = \frac{10}{3} \left(\frac{1}{4} - \frac{1}{6} \right) = \frac{10}{3} \times \frac{1}{6} = \frac{5}{9}$$

سپس $E[Y]$ را محاسبه می کنیم:

$$E[Y] = \int_0^1 f_Y y dy = 5 \int_0^1 y^5 dy = 5 \left[\frac{y^6}{6} \right]_0^1 = 5 \left(\frac{1}{6} - 0 \right) = \frac{5}{6}$$

در نهایت، کوواریانس $Cov(X, Y)$ را محاسبه می کنیم:

$$\begin{aligned} Cov(X, Y) &= E[XY] - E[X]E[Y] = \frac{10}{21} - \frac{5}{9} \times \frac{5}{6} = \frac{10}{21} - \frac{25}{54} \\ &= \frac{40}{84} - \frac{35}{84} = \frac{5}{84} = \frac{5}{378} \approx 0.0132 \end{aligned}$$

۴. بازگشت مصطفی!

۱۵ نمره

مصطفی پس از اخراج شدن از کار قبلی اش، تصمیم گرفته است تا به کمک دوستانش استارت آپی راه اندازی کند. برای این استارت آپ لازم است ۴ دپارتمان مدیریت، مارکتینگ، امور اجرایی و منابع انسانی هر کدام با ۵ عضو تشکیل شوند. پس مصطفی دوستانش را که شامل ۵ نفر از دانشکده کامپیوتر، ۵ نفر از دانشکده برق، ۵ نفر از دانشکده صنایع و ۵ نفر از دانشکده مدیریت بودند، دور هم جمع کرده و بدون بررسی توانایی و حوزه کاری هر فرد، صرفاً آن ها را بصورت تصادفی به داخل این ۴ دپارتمان ۵ نفره می فرستد.

اگر N_i تعداد دانشجویان صنایع در دپارتمان i ام باشد:

(الف) $\text{Cov}(N_1, N_2)$ را حساب کنید. (۱۰ نمره)

راهنمایی:

برای حل سوال از متغیرهای شاخص S_i و T_i استفاده کنید که:متغیر شاخص S_i برابر با ۱ است اگر دانشجوی صنایع i ام در دپارتمان اول قرار گیرد:

$$N_1 = \sum_{i=1}^5 S_i$$

و متغیر شاخص T_i برابر با ۱ است اگر دانشجوی صنایع i ام در دپارتمان دوم قرار گیرد:

$$N_2 = \sum_{i=1}^5 T_i$$

(ب) ضریب همبستگی بین $N_1 + N_2$ و $N_3 + N_4$ را بیابید. (با محاسبات ساده می توان پاسخ را به دست آورد). (۵ نمره)

پاسخ:

(الف)

$$E[N_1 N_2] = E \left[\left(\sum_{i=1}^5 S_i \right) \left(\sum_{j=1}^5 T_j \right) \right] = \sum_{i=1}^5 \sum_{j=1}^5 E[S_i T_j] = \sum_{i=1}^5 \sum_{j=1}^5 \Pr(S_i = 1, T_j = 1)$$

از آنجا که یک دانشجو نمی تواند در دو گروه قرار بگیرد $\Pr(S_i = 1, T_j = 1)$ در حالت $i = j$ برابر صفر است. در حالت $i \neq j$ داریم:

$$\Pr(S_i = 1, T_j = 1) = \Pr(S_i = 1) \Pr(T_j = 1 | S_i = 1)$$

احتمال قرارگیری دانشجوی صنایع i -ام در هر یک از چهار گروه یکسان است بنابراین:

$$P(S_i = 1) = \frac{1}{4}$$

اگر دانشجوی i -ام در گروه اول قرار داشته باشد، برای دانشجوی j -ام ۱۹ جای خالی باقی است، ۴ جا در گروه اول و ۵ جا در هر یک از سه گروه دیگر.
از این ۱۹ جا ۵ تا متعلق به گروه دوم است بنابراین:

$$P(T_j = 1 | S_i = 1) = \frac{5}{19}$$

از ۲۵ زوج (i, j) ، ۲۰ زوج غیر یکسان هستند، پس داریم:

$$E[N_1 N_2] = 20 \times \frac{1}{4} \times \frac{5}{19} = \frac{25}{19}$$

$$E[N_1] = \sum_{i=1}^5 E[S_i] = \frac{5}{4} = E[N_2]$$

پس با توجه به تعریف کوواریانس داریم:

$$\text{Cov}(N_1, N_2) = \frac{25}{19} - \frac{25}{16}$$

ب) متغیر تصادفی $A = N_1 + N_2$ را تعریف می کنیم. واضح است که $N_3 + N_4 = 5 - A$ بنابراین:

$$\rho(A, 5 - A) = \frac{\text{Cov}(A, 5 - A)}{\sqrt{\text{Var}(A) \cdot \text{Var}(5 - A)}} = \frac{-\text{Cov}(A, A)}{\sqrt{\text{Var}(A) \cdot \text{Var}(A)}} = -\frac{\text{Var}(A)}{\text{Var}(A)} = -1$$

یا مستقیماً با استفاده از خواص ضریب همبستگی داریم:

$$\rho(A, 5 - A) = \rho(A, -A) = -1$$

۵. مهندس مشکوک!

۱۵ نمره

یک سکه‌ی ناشناخته داریم که توسط یک مهندس طراحی شده است. مهندس ادعا می‌کند که به طور میانگین، احتمال شیر آمدن سکه ۴ درصد و با انحراف معیار ۰.۲ می‌باشد.

الف) می‌خواهیم احتمال شیر آمدن سکه (P) را با توزیع بتا مدل‌سازی کنیم ($P \sim \text{Beta}(\alpha, \beta)$). پارامترهای α و β این توزیع را پیدا کنید. (یافتن دو معادله‌ی دو مجهولی هم کافیه، در بخش‌های بعدی لازم به جایگذاری الفا و بتا نیست.) (۴ نمره)

مهندس از ادعای خود خیلی هم مطمئن نیست، به همین خاطر سکه را ۱ بار پرتاب می‌کند تا دیدگاه خودش از توزیع پیشین P را شفاف‌تر کند. فرض کنید X را نتیجه‌ی پرتاب سکه بنامیم و در این ۱ پرتاب، پیشامد مشاهده شده $X = x_1$ باشد.

ب) به کمک قانون بیز، تابع چگالی توزیع پسین $P(f_P(p|x_1))$ را بیابید. (لازم به محاسبه‌ی ثوابتی که تابعی از p نیستند، نیست) (۶ نمره)

راهنمایی:

در آزمایش پرتاب سکه، چون در حالت عادی احتمال شیر آمدن سکه (p) را می‌دانیم، اگر نتیجه‌ی پرتاب سکه را X بنامیم از توزیع برنولی پیروی کرده و داریم:

$$X \sim \text{Ber}(p)$$

$$\Pr_X(x) = p^x(1-p)^{1-x}$$

اما در تعبیر بیزی، خود P را که احتمال شیر آمدن است با توزیع بتا با پارامترهای α و β مدل‌سازی می‌کنیم، پس خواهیم داشت:

$$P \sim \text{Beta}(\alpha, \beta)$$

$$X|P \sim \text{Ber}(P)$$

$$\Pr_X(x|p) = p^x(1-p)^{1-x}$$

حالا فرض کنید مهندس از همان اول بجای یک بار پرتاب، سکه را n بار پرتاب کند و در این n پرتاب، مجموعه نتایج مشاهده شده روی سکه این‌ها باشند:

$$D = \{x_1, x_2, \dots, x_n\}$$

ج) در این حالت هم تابع چگالی توزیع پسین $P(f_P(p|D))$ را بیابید. (۵ نمره امتیازی)

پاسخ:

الف) با توجه به روابطی که برای توزیع بتا داریم و اطلاعاتی که مهندس به ما داده است، داریم:

$$E(X) = \frac{\alpha}{\alpha + \beta} = \frac{4}{100}$$

$$Var(X) = \frac{\alpha\beta}{(\alpha + \beta + 1)(\alpha + \beta)^2} = (0.2)^2$$

ب) با توجه به قانون بیز داریم: (دقت کنید که P از توزیع بتا است و پیوسته است و $X|P$ از توزیع برنولی است و گسسته است)

$$f_P(p|x_1) = \frac{\Pr(X = x_1|P = p) \cdot f_P(p)}{\Pr(X = x_1)} = \frac{p^{x_1}(1-p)^{(1-x_1)} \cdot \frac{1}{\rho(\alpha, \beta)} p^{(\alpha-1)}(1-p)^{(\beta-1)}}{\Pr(X = x_1)}$$

چون نیازی به محاسبه عباراتی که تابعی از p نیستند نداریم، پس:

$$f_P(p|x_1) = C \cdot p^{x_1}(1-p)^{(1-x_1)} \cdot p^{(\alpha-1)}(1-p)^{(\beta-1)} = C \cdot p^{(x_1+\alpha-1)}(1-p)^{(1-x_1+\beta-1)}$$

* دقت کنید با توجه به فرمی که پاسخ نهایی دارد می توان فهمید که از توزیع بتا است و پارامترهای آن را هم می توان یافت:

$$f_P(p|x_1) = C \cdot p^{(x_1+\alpha)-1}(1-p)^{(1-x_1+\beta)-1}$$

$$P|X = x_1 \sim \text{Beta}(x_1 + \alpha, 1 - x_1 + \beta)$$

$$\Rightarrow P|X \sim \text{Beta}(X + \alpha, 1 - X + \beta)$$

ج) مجدداً با توجه به قانون بیز داریم:

$$f_P(p|D) = \frac{\Pr_{\vec{X}(D|p)} \cdot f_P(p)}{\Pr_{\vec{X}(D)}} = \frac{\Pr(X_1 = x_1, \dots, X_n = x_n|P = p) \cdot f_P(p)}{\Pr(X_1 = x_1, \dots, X_n = x_n)}$$

از طرفی می دانیم که n متغیر تصادفی X_1, \dots, X_n مستقل شرطی به شرط P هستند، پس داریم:

$$\begin{aligned} f_P(p|D) &= \frac{\prod_{i=1}^n \Pr(X_i = x_i|P = p) \cdot f_P(p)}{\Pr(X_1 = x_1, \dots, X_n = x_n)} = \frac{\prod_{i=1}^n p^{x_i}(1-p)^{(1-x_i)} \cdot \frac{1}{\rho(\alpha, \beta)} p^{(\alpha-1)}(1-p)^{(\beta-1)}}{\Pr(X_1 = x_1, \dots, X_n = x_n)} \\ &= \frac{p^{\sum_{i=1}^n x_i} (1-p)^{(n-\sum_{i=1}^n x_i)} \cdot \frac{1}{\rho(\alpha, \beta)} p^{(\alpha-1)}(1-p)^{(\beta-1)}}{\Pr(X_1 = x_1, \dots, X_n = x_n)} \\ &= C \cdot p^{\sum_{i=1}^n x_i} (1-p)^{(n-\sum_{i=1}^n x_i)} \cdot p^{(\alpha-1)}(1-p)^{(\beta-1)} \\ &= C \cdot p^{(\sum_{i=1}^n x_i + \alpha) - 1} (1-p)^{(n - \sum_{i=1}^n x_i + \beta) - 1} \end{aligned}$$

* دقت کنید با توجه به فرمی که پاسخ نهایی دارد، می توان فهمید که توزیع بتا است و پارامترهای آن هم می توان یافت:

$$f_P(p|D) = C \cdot p^{(\sum_{i=1}^n x_i + \alpha) - 1} (1-p)^{(n - \sum_{i=1}^n x_i + \beta) - 1}$$

$$\Rightarrow P|D \sim \text{Beta}\left(\sum_{i=1}^n x_i + \alpha, n - \sum_{i=1}^n x_i + \beta\right)$$

۶. نمره ی رایگان!

۱۵ نمره

گروهی از دانشجویهای دانشکده برق و کامپیوتر در یک چالش شرکت کرده اند. در این چالش یک تاس به نماینده ی دانشجویهای برق و یک تاس به نماینده ی دانشجویهای کامپیوتر داده می شود و هر کدام از آنها تا وقتی عدد ۶ بیاید، به تاس انداختن ادامه می دهند و اگر مجموع دفعاتی که این دو نفر تاس می اندازند تا هر دو ۶ بیاورند دقیقا ۲۰ بار بشود، تمام آن گروه دانشجویها در درس آمار و احتمال ۲۰ می گیرند. (مثلا اگر نماینده ی برق بعد از ۱۲ بار تاس انداختن و نماینده کامپیوتر بعد از ۸ بار تاس انداختن، ۶ بیاورند، برنده می شوند و همه ۲۰ می گیرند.)

الف) اگر بدانیم که این دانشجویها نهایتا در چالش برنده شده اند، توزیع احتمال تعداد دفعات تاس ریختن دانشجوی برق را بیابید. (۱۰ نمره)

ب) اگر بجای دو تاس معمولی، دو تاس ناعادلانه به آنها داده می شد که احتمال ۶ آمدن در آنها $\frac{1}{4}$ است و باز هم می دانستیم که در مسابقه برنده شده اند، آیا تغییری در توزیع احتمال تعداد دفعات تاس ریختن دانشجوی برق ایجاد می شد؟ توضیح دهید. (۵ نمره)

پاسخ:

الف) عددی که در هر پرتاب روی تاس دانشجوی برق ظاهر می شود را با متغیر تصادفی X و عددی که در هر پرتاب روی تاس دانشجوی کامپیوتر ظاهر می شود را با متغیر تصادفی Y نشان می دهیم. از طرفی می دانیم که نهایتا در چالش برنده شده اند پس $X + Y$ را داریم و مساوی ۲۰ است، اما در طول راه حل، برای یافتن پاسخ کلی، آنرا $X + Y = n$ می گذاریم و در انتها عدد ۲۰ را جایگذاری می کنیم.

با توجه به مستقل بودن X و Y نسبت به همدیگر و تمام حالات ممکن برای آنها با حاصل جمع معین داریم:

$$P(X + Y = n) = \sum_{i=1}^{n-1} P(X = i, Y = n - i) = \sum_{i=1}^{n-1} P(X = i)P(Y = n - i)$$

از طرفی بدیهتا هر دوی X و Y از توزیع هندسی با پارامتر $\frac{1}{4}$ پیروی می کنند که فعلا بجای آن p می گذاریم تا مسئله در حالت کلی حل شود و در نهایت $\frac{1}{4}$ را جایگذاری می کنیم.

$$P(X + Y = n) = \sum_{i=1}^{n-1} p(1-p)^{i-1} p(1-p)^{n-i-1} = (n-1)p^2(1-p)^{n-2}$$

حالا می توانیم توزیع احتمال تعداد دفعات تاس ریختن دانشجوی برق را با فرض دانستن تعداد کل تاس های ریخته شده محاسبه کنیم:

$$P(X = k | X + Y = n) = \frac{P(X = k, X + Y = n)}{P(X + Y = n)} = \frac{P(X = k, Y = n - k)}{P(X + Y = n)}$$

$$P(X = k | X + Y = n) = \frac{P(X = k)P(Y = n - k)}{(n-1)p^2(1-p)^{n-2}} = \frac{p(1-p)^{k-1}p(1-p)^{n-k-1}}{(n-1)p^2(1-p)^{n-2}}$$

$$P(X = k | X + Y = n) = \frac{1}{n-1}$$

پس متغیر تصادفی $X = k | X + Y = n$ هیچ تابعیتی از k نداشت که یعنی دارای توزیع یکنواخت است با جایگذاری مقدار n داریم:

$$P(X = k | X + Y = 20) = \frac{1}{19}$$

پس این متغیر تصادفی، توزیع یکنواخت گسسته روی مقادیر $X = 1, 2, \dots, 19$ دارد.

ب) خیر، همانطور که در راه حل بخش قبلی دیدیم، در ابتدا احتمال ۶ آمدن تاس را p گذاشتیم که در صورت لزوم جایگذاری کنیم، اما در پاسخ نهایی اثری از p نبود. پس توزیع احتمال تعداد دفعات تاس ریختن دانشجوی برق با فرض اینکه می دانیم بعد از مجموعاً ۲۰ بار تاس انداختن هر دو دانشجو ۶ آورده اند، مستقل از احتمال ۶ آمدن است و فقط کافیت که احتمال ۶ آمدن مخالف صفر باشد تا به همان توزیع یکنواخت گسسته روی مقادیر ۱ تا ۱۹ برسیم.

۷. تلاش آخر!

۱۵ نمره

مصطفی پس از ورشکست شدن استارت آپ اش، به همراه دوستانش یک کارخانه ی ساخت لوازم الکترونیکی راه انداخت. در این کارخانه دو خط تولید لامپ وجود دارد که خط تولید A را مهندسان برق، کنترل می کنند و ۶۰ درصد لامپ ها در همین خط تولید ساخته می شوند و خط تولید B را مهندسان صنایع کنترل می کنند و ۴۰ درصد لامپ ها در این خط تولید، ساخته می شوند.

از آنجایی که مهندسان برق دانش بیشتری در زمینه ی ساخت قطعات الکترونیکی دارند، طول عمر لامپ های خط تولید A از لامپ های خط تولید B بیشتر است. فرض کنید $T_A \sim \text{Exp}(1)$ توزیع طول عمر لامپ های خط تولید A است و $T_B \sim \text{Exp}(2)$ توزیع طول عمر لامپ های خط تولید B است. توجه کنید که در نهایت، تولیدات هر دو خط تولید با هم مخلوط شده و روانه ی بازار می شوند.

الف) اگر T را توزیع طول عمر نهایی محصولات ی که وارد بازار می شوند بگیریم، PDF آن را بیابید. (۵ نمره)

ب) یکی از مشتری های این کارخانه، لامپی خریده که بعد از مدتی خراب شده است. احتمال اینکه این لامپ توسط خط تولید شده های صنایع تولید شده باشد چقدر است؟ (۵ نمره)

ج) اگر میانگین طول عمر محصولات این کارخانه از ۱ واحد کمتر باشد، توسط بازرس ها پلمپ می شود. آیا این کارخانه هم پلمپ می شود و مصطفی دوباره بیکار خواهد شد؟ (۵ نمره)

پاسخ:

الف) فرض کنید يك قطعه را بصورت تصادفی از خروجی کارخانه برداشته ایم، متغیر برنولی $X \sim \text{Bernoulli}(0.4)$ را به صورت زیر تعریف می کنیم:

$$X = \begin{cases} 0 & \text{اگر قطعه در خط تولید A تولید شده باشد} \\ 1 & \text{اگر قطعه در خط تولید B تولید شده باشد} \end{cases}$$

پس احتمال انتخاب هر خط تولید به شرح زیر است:

$$P(X = 0) = 0.6, \quad P(X = 1) = 0.4$$

حال، برای یافتن تابع چگالی احتمال (PDF) طول عمر T یک قطعه به صورت کلی، از قانون احتمال کل استفاده می‌کنیم:

$$f_T(t) = f_{T|X}(t|\cdot)P_X(\cdot) + f_{T|X}(t|1)P_X(1)$$

با جایگذاری مقادیر داده شده:

$$f_T(t) = (e^{-t}) \times 0.6 + (2e^{-2t}) \times 0.4$$

با ساده‌سازی:

$$f_T(t) = 0.8e^{-2t} + 0.6e^{-t}$$

بنابراین، تابع چگالی احتمال کلی طول عمر T برابر است با:

$$f_T(t) = 0.8e^{-2t} + 0.6e^{-t}, \quad t \geq 0$$

(ب) فرض کنید لامپی که توسط مشتری خریداری شده است، بعد از مدت t خراب شده است. می‌خواهیم احتمال اینکه این لامپ توسط خط تولید B (دانشجوه‌های صنایع) تولید شده باشد را محاسبه کنیم.

با استفاده از قانون بیز داریم:

$$P_{X|T}(1 | t) = \frac{f_{T|X}(t | 1) \cdot P_X(1)}{f_T(t)}$$

(از آنجایی که T پیوسته است، باید از چگالی احتمال T استفاده کنیم) با جایگذاری مقادیر:

$$\begin{aligned} P_{X|T}(1 | t) &= \frac{2e^{-2t} \cdot 0.4}{0.8e^{-2t} + 0.6e^{-t}} = \frac{0.8e^{-2t}}{0.8e^{-2t} + 0.6e^{-t}} \\ &= \frac{0.8}{0.8 + 0.6e^t}, \quad t \geq 0 \end{aligned}$$

(ج) برای محاسبه میانگین طول عمر $E[T]$ ، از تابع چگالی احتمال $f_T(t)$ استفاده می‌کنیم:

$$E[T] = \int_0^{\infty} t \cdot f_T(t) dt$$

جایگذاری $f_T(t)$:

$$\begin{aligned} E[T] &= \int_0^{\infty} t \cdot (0.8e^{-2t} + 0.6e^{-t}) dt \\ E[T] &= 0.8 \int_0^{\infty} t \cdot e^{-2t} dt + 0.6 \int_0^{\infty} t \cdot e^{-t} dt \end{aligned}$$

انتگرال‌های فوق با انتگرال‌گیری جز به جز براحتی محاسبه می‌شوند:

$$E[T] = 0.8 \cdot \frac{1}{4} + 0.6 \cdot 1 = 0.2 + 0.6 = 0.8$$

بنابراین، میانگین طول عمر $E[T] = 0.8$ است که کمتر از ۱ واحد می‌باشد. در نتیجه، شرکت توسط بازرس‌ها پلمپ خواهد شد و مصطفی دوباره بیکار خواهد شد! :